CLEAR

Cross-Lingual Enhancement in Retrieval via Reverse-training

2026.09.16.

Jungyeon Lee

핵심 내용

Cross-lingual retrieval을 개선하면서 기존 영어 retrieval 능력을 유지할 수 있는가?

Propose a loss function utilizing a reverse training scheme to improve retrieval performance across diverse cross-lingual retrieval scenarios

문제

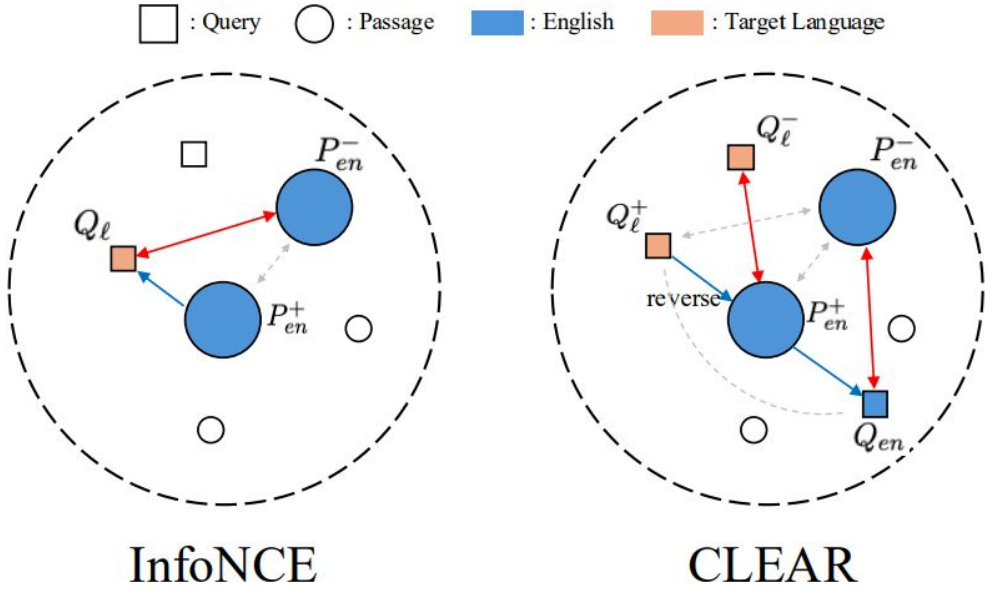
대상 언어의 검색 품질과 영어 성능을 함께 고려해야 한다.

제안

영어 passage를 공유하고, passage를 anchor로 질문을 구분한다.

검증

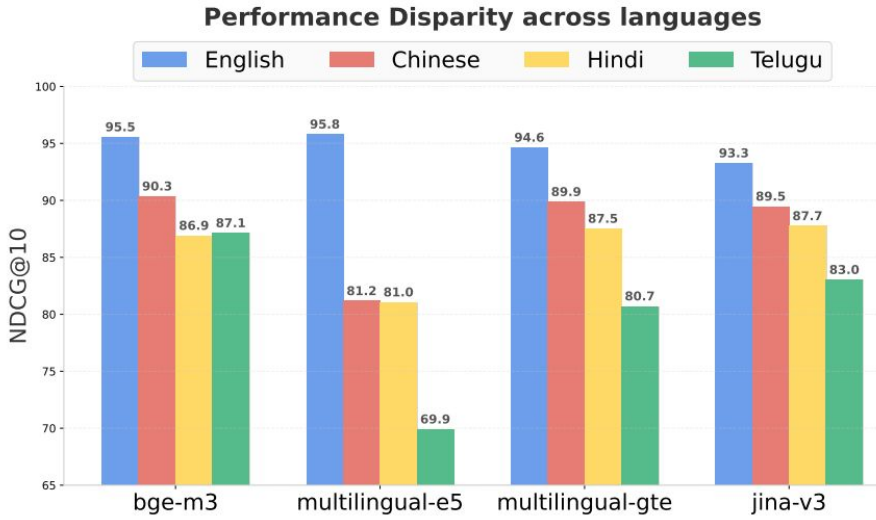
검색 방향, 언어 수, loss 구성 요소를 바꾸어 효과를 확인한다.



기존 방식의 한계

Imbalanced linguistic resources, insufficient attention to cross-lingual alignment during training

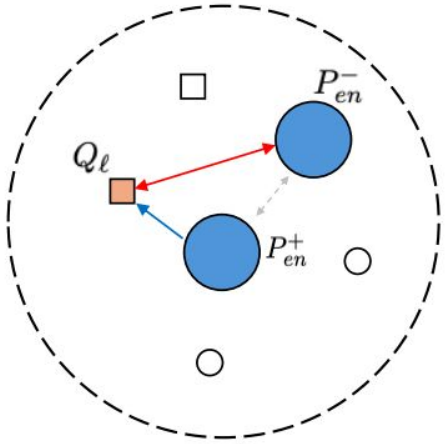
한계	논문이 지적한 문제
언어별 성능 격차	**저자원 언어에서 검색 품질이 낮아짐**
Query 중심 학습	정답 문서 구분을 넘어선 정렬이 충분한가?
영어 성능 저하	언어 간 적응 중 기존 영어 능력을 잃을 수 있음
병렬 데이터 의존	많은 병렬 자료를 요구하는 접근법들



기존 방식의 한계

Imbalanced linguistic resources, insufficient attention to cross-lingual alignment during training

한계	논문이 지적한 문제
언어별 성능 격차	저자원 언어에서 검색 품질이 낮아짐
Query 중심 학습	**정답 문서 구분을 넘어선 정렬이 충분한가?**
영어 성능 저하	언어 간 적응 중 기존 영어 능력을 잃을 수 있음
병렬 데이터 의존	많은 병렬 자료를 요구하는 접근법들



InfoNCE

기존 방식의 한계

Imbalanced linguistic resources, insufficient attention to cross-lingual alignment during training

한계	논문이 지적한 문제
언어별 성능 격차	저자원 언어에서 검색 품질이 낮아짐
Query 중심 학습	정답 문서 구분을 넘어선 정렬이 충분한가?
영어 성능 저하	**언어 간 적응 중 기존 영어 능력을 잃을 수 있음**
병렬 데이터 의존	**많은 병렬 자료를 요구하는 접근법들**

CLEAR의 전체 목적함수

영어 학습과 언어 간 학습을 같은 영어 passage로 연결한다.

$$\mathcal{L}_{\text{CLEAR}} = \lambda_1 \cdot \mathcal{L}_{\text{NCE}_{en}} + \lambda_2 \cdot \mathcal{L}_{\text{CL}} + \lambda_3 \cdot \mathcal{L}_{\text{KL}}$$

항	역할
$\mathcal{L}_{\text{NCE}_{en}}$	이 영어 query에 맞는 영어 passage를 구분하도록
$\mathcal{L}_{\text{CL}}$	이 영어 passage에 맞는 대상 언어 query를 구분하도록
$\mathcal{L}_{\text{KL}}$	대응 query들이 만드는 유사도 관계의 분포

CLEAR의 전체 목적함수

영어 학습과 언어 간 학습을 같은 영어 passage로 연결한다.

$$\mathcal{L}_{\text{CLEAR}} = \lambda_1 \cdot \mathcal{L}_{\text{NCE}_{en}} + \lambda_2 \cdot \mathcal{L}_{\text{CL}} + \lambda_3 \cdot \mathcal{L}_{\text{KL}}$$

항	역할
$\mathcal{L}_{\text{NCE}_{en}}$	**이 영어 query에 맞는 영어 passage를 구분하도록**
$\mathcal{L}_{\text{CL}}$	이 영어 passage에 맞는 대상 언어 query를 구분하도록
$\mathcal{L}_{\text{KL}}$	대응 query들이 만드는 유사도 관계의 분포

$$\mathcal{L}_{NCE} = -\frac{e^{\text{sim}(q_i, p_i^+)/\tau}}{e^{\text{sim}(q_i, p_i^+)/\tau} + \sum_j e^{\text{sim}(q_i, p_{ij}^-)/\tau}}$$

CLEAR의 전체 목적함수

영어 학습과 언어 간 학습을 같은 영어 passage로 연결한다.

$$\mathcal{L}_{\text{CLEAR}} = \lambda_1 \cdot \mathcal{L}_{\text{NCE}_{en}} + \lambda_2 \cdot \mathcal{L}_{\text{CL}} + \lambda_3 \cdot \mathcal{L}_{\text{KL}}$$

항	역할
$\mathcal{L}_{\text{NCE}_{en}}$	이 영어 query에 맞는 영어 passage를 구분하도록
$\mathcal{L}_{\text{CL}}$	**이 영어 passage에 맞는 대상 언어 query를 구분하도록**
$\mathcal{L}_{\text{KL}}$	대응 query들이 만드는 유사도 관계의 분포

$$\mathcal{L}_{\text{CL}}(p_{en_i}, q^+_{\ell_i}, q^-_{\ell_{ij}}) = -\frac{e^{z_i^+/\tau}}{e^{z_i^+/\tau} + \sum_j e^{z_{ij}^-/\tau}}$$

where z_i^+ and z_{ij}^- is defined as:

$$z_i^+ = \text{sim}(p_{en_i}, q^+_{\ell_i}),\ z_{ij}^- = \text{sim}(p_{en_i}, q^-_{\ell_{ij}})$$

CLEAR의 전체 목적함수

영어 학습과 언어 간 학습을 같은 영어 passage로 연결한다.

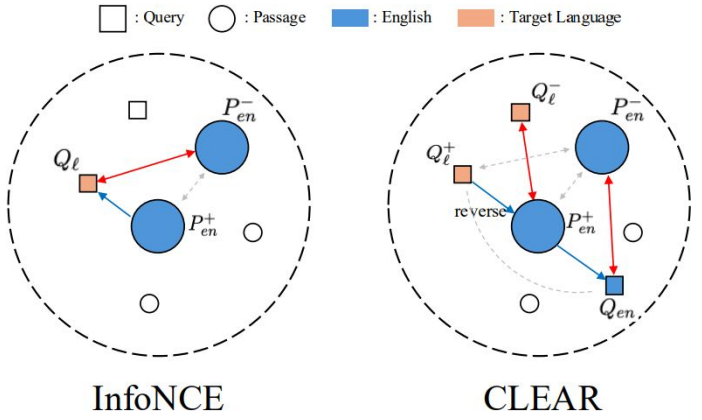
$$\mathcal{L}_{\text{CLEAR}} = \lambda_1 \cdot \mathcal{L}_{\text{NCE}_{en}} + \lambda_2 \cdot \mathcal{L}_{\text{CL}} + \lambda_3 \cdot \mathcal{L}_{\text{KL}}$$

항	역할
$\mathcal{L}_{\text{NCE}_{en}}$	이 영어 query에 맞는 영어 passage를 구분하도록
$\mathcal{L}_{\text{CL}}$	이 영어 passage에 맞는 대상 언어 query를 구분하도록
$\mathcal{L}_{\text{KL}}$	**대응 query들이 만드는 유사도 관계의 분포**

$$\text{KL}(S_{en} \parallel S_{CL}) = \sum_{i,j} S_{en}[i,j] \log \frac{S_{en}[i,j]}{S_{CL}[i,j]}$$

$\mathcal{L}_{CL}$: passage에서 정답 query를 찾는 학습

Reversal scheme은 anchor와 경쟁 후보의 역할을 바꾼다.



역할	InfoNCE baseline	CLEAR의 L_CL
Anchor	대상 언어 query	**영어 passage**
Positive	영어 정답 passage	**대응하는 대상 언어 query**
Negatives	관련 없는 영어 passages	**관련 없는 대상 언어 queries**

“이 문서에 맞는 질문은 무엇인가?”를 여러 질문 후보 사이에서 학습한다.

Passage bridge: 두 loss가 공유하는 기준

동일한 영어 passage가 영어 query와 대상 언어 query를 연결한다.

학습 항	공유하는 관계	목적
$\mathcal{L}_{\mathrm{NCE}_{en}}$	영어 query + 영어 passage	영어 검색 관계 유지
$\mathcal{L}_{\mathrm{CL}}$	같은 영어 passage + 대상 언어 query	언어 간 정렬

공통 passage를 통해 대응 query들의 정렬을 간접적으로 유도한다.

$\mathcal{L}_{\mathrm{KL}}$: 유사도 관계의 분포를 맞춘다

정답쌍뿐 아니라 배치 안의 다른 query–passage 관계도 비교한다.

$$\mathrm{KL}(S_{en} \parallel S_{CL}) = \sum_{i,j} S_{en}[i,j] \log \frac{S_{en}[i,j]}{S_{CL}[i,j]}$$

where $S_{en}[i,j] = \mathrm{sim}(q_{en_i}, p_{en_j})$ and $S_{CL}[i,j] = \mathrm{sim}(p_{en_j}, q_{\ell_i})$

두 언어의 query가 공통 영어 passages를 비슷하게 평가하도록 유도

각 loss가 주는 학습 신호

대조학습(NCE/CL)과 분포 정렬(KL)은 서로 다른 제약을 제공한다.

항	모델이 구분하거나 맞추는 것
$\mathcal{L}_{\mathrm{NCE}_{en}}$	이 영어 query에 맞는 영어 passage
$\mathcal{L}_{\mathrm{CL}}$	이 영어 passage에 맞는 대상 언어 query
$\mathcal{L}_{\mathrm{KL}}$	대응 query들이 만드는 유사도 관계의 분포

대조학습의 정답 구분에, 언어 간 관계 패턴의 일관성을 추가한다.

Experimental Setup

동일한 기반 모델에 Base / InfoNCE / CLEAR를 비교한다.

항목	설정
기반 모델	bge-m3 / multilingual-e5-base / gte-multilingual-base / jina-v3
학습 자료	MIRACL 영어 + MLQA, NLLB 질문 번역
학습량	대상 언어별 12,698개, 1 epoch
주요 설정	**Batch 64 / LR 5e−5 / 최대 길이 512**
비교 목적	같은 모델에서 CLEAR가 InfoNCE보다 나은가?

Evaluation

Belebele와 XQuAD의 병렬 QA 자료를 passage 검색 과제로 활용한다.

평가 조건	확인하는 능력
대상 언어 query / 영어 passage	직접 학습한 언어 조합의 검색
영어 query / 대상 언어 passage	추가 학습에서 다루지 않은 문서 언어로의 전이
영어 query / 영어 passage	기존 영어 검색 능력 유지
여러 언어 joint training	여러 대상 언어를 함께 처리하는 효과
XOR-TyDi 추가 평가	다른 검색 벤치마크에서의 재검증

Results

nDCG@10 : 상위 10개 안에서 관련 passage가 얼마나 높은 순위에 있는지 평가한다.

Model	Language	English-English		English-Lang			Lang-English		
		InfoNCE	CLEAR	Base	InfoNCE	CLEAR	Base	InfoNCE	CLEAR
					Belebele				
bge-m3	zh	94.65 (-0.90)	**95.47 (-0.08)**	90.35	91.69	**92.64**	89.81	91.63	**92.02**
	es	95.51 (-0.04)	**96.14 (+0.59)**	91.99	92.81	**93.39**	92.05	93.50	**93.82**
	de	95.61 (+0.06)	**96.11 (+0.56)**	92.81	93.98	**94.58**	92.90	94.30	**94.52**
	hi	95.15 (-0.40)	**95.75 (+0.20)**	86.90	89.14	**90.16**	90.39	92.86	**93.16**
	vi	95.14 (-0.41)	**95.79 (+0.24)**	92.58	93.04	**93.12**	93.04	92.58	**93.54**
	te	94.93 (-0.62)	**95.74 (+0.19)**	87.12	89.07	**90.12**	89.19	92.08	**92.74**
	bn	95.18 (-0.37)	**95.81 (+0.26)**	87.58	89.79	**90.85**	90.17	92.37	**93.08**
multilingual-e5	zh	94.18 (-1.61)	**95.06 (-0.73)**	81.16	87.00	**88.89**	85.49	90.02	**90.75**
	es	94.38 (-1.41)	**95.40 (-0.39)**	89.46	89.84	**91.61**	92.43	92.15	**93.13**
	de	94.49 (-1.30)	**95.06 (-0.73)**	90.77	90.97	**91.94**	92.16	92.68	**92.86**
	hi	94.11 (-1.68)	**95.28 (-0.51)**	81.05	83.11	**86.10**	88.44	91.08	**92.13**
	vi	94.22 (-1.57)	**95.07 (-0.72)**	86.03	87.11	**88.63**	88.58	91.81	**91.95**
	te	93.80 (-1.99)	**95.11 (-0.68)**	69.90	77.14	**80.97**	84.88	88.05	**88.99**
	bn	93.83 (-1.96)	**95.28 (-0.51)**	75.55	81.81	**85.44**	84.31	88.91	**89.92**
gte-multilingual	zh	94.38 (-0.25)	**95.15 (+0.52)**	89.86	92.30	**92.67**	91.51	92.05	**92.80**
	es	95.51 (+0.88)	**95.73 (+1.10)**	91.71	92.86	**93.28**	90.20	93.55	**93.87**
	de	95.32 (+0.69)	**95.67 (+1.04)**	91.21	92.92	**93.26**	89.42	93.45	**93.95**
	hi	94.93 (+0.30)	**95.40 (+0.77)**	87.51	89.34	**89.96**	89.55	92.45	**93.05**
	vi	95.02 (+0.39)	**95.71 (+1.08)**	89.37	91.59	**92.23**	90.48	93.14	**93.52**
	te	94.63 (0.00)	**95.32 (+0.69)**	80.70	84.77	**86.31**	88.46	89.96	**90.92**
	bn	94.54 (-0.09)	**95.40 (+0.77)**	82.13	85.18	**86.64**	87.81	91.03	**92.14**
jina-v3	zh	94.97 (+1.71)	**95.31 (+2.05)**	89.46	91.90	**92.67**	89.64	91.74	**92.18**
	es	95.21 (+1.95)	**95.66 (+2.40)**	91.40	93.57	**94.29**	92.64	**93.88**	93.86
	de	95.29 (+2.03)	**95.62 (+2.36)**	91.75	93.88	**94.46**	92.39	94.12	**94.46**
	hi	94.01 (+0.75)	**95.59 (+2.33)**	87.74	89.90	**90.70**	91.50	93.02	**93.34**
	vi	94.01 (+0.75)	**95.50 (+2.24)**	90.26	**92.68**	92.63	90.98	93.12	**93.40**
	te	91.33 (-1.93)	**95.69 (+2.43)**	83.02	85.57	**87.32**	88.99	91.87	**92.58**
	bn	94.01 (+0.75)	**95.75 (+2.49)**	86.56	89.22	**90.89**	91.14	**93.52**	93.43
Total	Average	94.58 (-0.22)	**95.52 (+0.71)**	87.00	89.36	**90.56**	89.95	92.18	**92.72**

					XQuAD				
bge-m3	ar	96.29 (-0.88)	**96.72 (-0.45)**	92.24	93.08	**93.50**	92.38	94.41	**94.71**
	zh	96.13 (-1.04)	**96.70 (-0.47)**	94.04	94.03	**94.68**	93.18	94.21	**94.82**
	es	96.80 (-0.37)	**96.91 (-0.26)**	96.14	95.97	**96.14**	95.96	**96.42**	96.34
	ru	96.24 (-0.93)	**96.91 (-0.26)**	95.58	95.13	**95.83**	94.57	94.98	**95.16**
multilingual-e5	ar	94.70 (-3.32)	**96.23 (-1.79)**	87.29	87.58	**89.83**	91.22	91.69	**92.61**
	zh	95.22 (-2.80)	**96.01 (-2.01)**	89.60	90.64	**91.71**	91.02	92.44	**93.44**
	es	95.51 (-2.51)	**95.94 (-2.08)**	**96.15**	93.39	94.00	**96.41**	94.42	94.62
	ru	95.18 (-2.84)	**95.94 (-2.08)**	**93.06**	91.90	92.54	**93.22**	92.54	93.11
gte-multilingual	ar	94.70 (-3.32)	**96.23 (-1.79)**	87.29	87.58	**89.83**	91.22	91.69	**92.61**
	zh	96.84 (-1.09)	**97.43 (-0.50)**	93.98	94.27	**94.87**	92.07	93.67	**94.05**
	es	97.56 (-0.37)	**97.59 (-0.34)**	96.14	95.88	**96.45**	95.79	96.53	**96.66**
	ru	97.04 (-0.89)	**97.40 (-0.53)**	94.38	94.06	**94.57**	94.24	94.88	**95.21**
jina-v3	ar	**97.24 (+1.15)**	97.16 (+1.07)	90.58	93.25	**93.90**	93.21	95.02	**95.19**
	zh	97.31 (+1.22)	**97.33 (+1.24)**	92.65	94.72	**95.05**	92.79	95.36	**95.75**
	es	**97.36 (+1.27)**	97.17 (+1.08)	94.76	**96.00**	95.92	96.12	96.99	**97.02**
	ru	**97.25 (+1.16)**	97.19 (+1.10)	93.97	95.88	**96.06**	94.38	95.53	**95.82**
Total	Average	96.47 (-0.84)	**96.88 (-0.44)**	93.00	93.40	**94.05**	93.65	94.52	**94.89**

저자원 언어에서 큰 개선 사례

Belebele · multilingual-e5 · 대상 언어 query / 영어 passage

언어	Base	InfoNCE	CLEAR	추가 이득
Telugu	69.90	77.14	**80.97**	**+3.83**
Bengali	75.55	81.81	**85.44**	**+3.63**

“CLEAR의 효과”는 같은 모델의 InfoNCE와 비교해야 한다.

학습하지 않은 언어 조합에도 전이

Belebele · multilingual-e5 · 영어 query / 대상 언어 passage

문서 언어	InfoNCE	CLEAR	차이
Telugu	88.05	**88.99**	+0.94
Bengali	88.91	**89.92**	+1.01

Observation: 대상 언어 passage 검색 성능도 개선

저자의 해석: 영어와 대상 언어의 표현 정렬이 더 견고해짐

영어 검색 성능 저하를 완화

Table 1의 English–English 평균. 괄호는 Base 대비 변화이다.

벤치마크	InfoNCE	CLEAR
Belebele	94.58 (−0.22)	**95.52 (+0.71)**
XQuAD	96.47 (−0.84)	96.88 (−0.44)

영어 유지의 효과는 “완전한 방지”보다 “평균적인 저하 완화”

여러 언어를 동시에 학습하면?

언어당 1,410개를 결합한 9개 언어 joint training: 총 12,690개

Query / Passage	InfoNCE	CLEAR
중국어 / 영어	86.84	**88.85**
텔루구어 / 영어	76.48	**80.22**
영어 / 중국어	90.02	**90.78**
영어 / 텔루구어	88.63	**89.50**

공동 학습 조건에서도 CLEAR의 이득이 유지된다.

같은 언어끼리의 검색에도 이득

다국어 공동 학습 후, query와 passage를 같은 언어로 평가한다.

Query = Passage 언어	InfoNCE → CLEAR
영어	**94.94 → 95.61**
중국어	**91.28 → 93.05**
텔루구어	**80.67 → 82.81**
벵골어	**85.28 → 87.56**

학습은 multilingual, 이 표의 평가는 monolingual이다.

Ablation

multilingual-e5 평균. 전체 CLEAR에서 한 요소씩 제거하거나 변경한다.

조건	대상 query / 영어 문서	영어 query / 대상 문서
CLEAR	**87.55**	**91.12**
KL 제거	86.92	90.72
Reverse를 일반 방향으로	85.97	90.18
영어 InfoNCE 제거	85.80	89.67

영어 학습·역방향이 기여하고, KL은 평균적으로 추가 이득을 준다.

Appendix의 보완 실험

추가 벤치마크, 번역 모델, 가중치에 대한 민감도를 확인한다.

실험	논문의 결과	해석 범위
XOR-TyDi	네 모델 모두 평균 개선	추가 검색 벤치마크
번역기 교체	m2m100에서도 개선 경향	특정 번역기에만 국한되지 않음
Loss 가중치	조사 범위에서 비교적 안정적	모든 조합을 검증한 것은 아님
확장 결과	추가 언어, nDCG@5 포함	본문 결과의 범위 보완

장점 및 한계점

장점

대상 언어 문서 없이 추가 학습

네 기반 모델에서 효과 확인

영어 유지와 반대 방향 평가

다양한 보완 실험

남은 질문

비영어 언어끼리의 검색에도 전이될 수 있는가?

더 강한 최신 backbone에도 이득이 남는가?

Alignment가 개선의 직접 원인인가?

반복 seed·신뢰구간과 최종 RAG 효과는?

아이디어 확장 및
후속 연구 제안

1: 비영어 언어쌍 평가

제안 질문: 영어와 각각 정렬한 언어들은 서로도 잘 검색할 수 있는가?

평가 범위

학습 언어쌍 / 비영어 언어쌍 / 미학습 언어 / 다국어 혼합 corpus

데이터 분할

원본 문서·의미 단위로 분리해 번역본 간 누출 방지

비교와 지표

영어 bridge vs 다중 bridge, 평균·최저 언어쌍 점수와 방향 격차

2: 최신 backbone과 RAG

제안 질문: 검색 loss의 이득이 강한 모델과 실제 답변 품질에도 이어지는가?

강한 임베딩 모델

동일 checkpoint의 Base / InfoNCE / CLEAR 비교

RAG 연결

Generator와 prompt를 고정하고 retriever만 변경

평가의 확장

검색 nDCG와 답변 정확도·근거 충실도·언어별 격차를 함께 측정