VGGT: Visual Geometry Grounded Transformer

3D Reconstruction with a comparison to DUSt3R

2026. 09. 22

Seonyeong Jeong

Covered Paper

VGGT: Visual Geometry Grounded Transformer (CVPR 2025)

Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, David Novotny



Main topic

Unposed images로부터
Cameras와 dense 3D geometry를 공동 예측

→ **Feed-forward 3D reconstruction**

Comparison: DUSt3R (CVPR 2024)

- Pairwise point map prediction
- Global alignment

VGGT (CVPR 2025); DUSt3R (CVPR 2024)

Preliminaries

Depth map / Point map

Representation	Pixel에 저장되는 값	의미
Depth map	$d \in \mathbb{R}$	해당 camera 기준 **depth**
Point map	$(x, y, z) \in \mathbb{R}^3$	지정된 reference frame의 **3D 좌표**

Introduction

Background: Geometry Optimization에 의존하는 3D Reconstruction

기존 방법은 Bundle Adjustment 등 iterative optimization으로 3D geometry를 추정함

Learning을 결합한 SfM에서도 geometry optimization의 복잡성과 계산 비용이 남아 있음

DUSt3R, MASt3R은 두 images를 처리하며, 여러 view의 복원에는 pairwise 결과의 사후 통합이 필요함

Research Question

Geometry post-processing을 최소화하면서, neural network가 **3D attributes를 직접 예측**할 수 있는가?

VGGT: Feed-forward joint prediction of 3D attributes

- 하나부터 수백 개의 input views를 처리하고 cameras, depth maps, point maps, point tracks를 예측함
- Shared Transformer backbone에서 관련 3D attributes를 함께 학습하여 정확도를 높임
- 사후 optimization 없이 사용 가능한 결과를 생성하며, BA를 추가하면 정확도가 더 향상됨
- 학습한 features를 dynamic point tracking과 novel view synthesis에도 활용함

VGGT §1 Introduction

DUSt3R: Pairwise Point Map Prediction

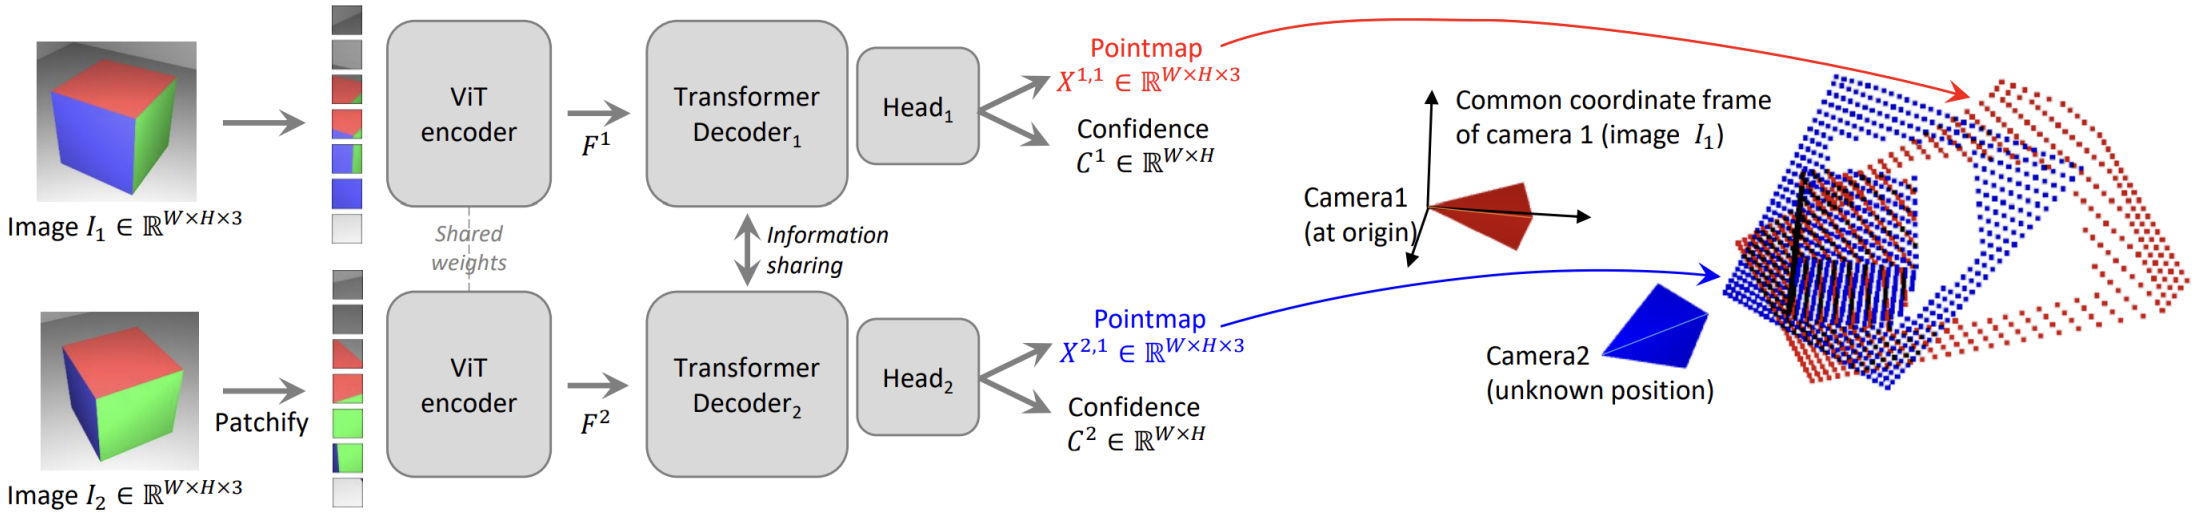


Image pair의 geometry를 직접 regression

Shared ViT encoder로 두 images를 encode하고, 두 decoder가 cross-attention으로 정보를 교환함

각 head는 point map과 confidence를 예측하고, 두 point maps는 첫 번째 camera의 좌표계로 정렬됨

Camera intrinsics, poses를 사전에 입력할 필요가 없음

DUSt3R §3.1; Figure 2; DUSt3R slides p.8

DUSt3R: Multi-view Global Alignment

Pairwise prediction을 전체 scene으로 통합

1. 여러 images로부터 overlapping image pairs를 구성함
2. 각 pair에 대해 point maps와 confidence를 예측함
3. Pair별 coordinate frame과 scale을 global alignment로 조정함



이미 pair 안에서는 정렬되어 있는데, 왜 추가 정합이 필요한가?

한 pair의 두 point maps는 같은 좌표계이지만, 서로 다른 pair의 reference frame은 다를 수 있음

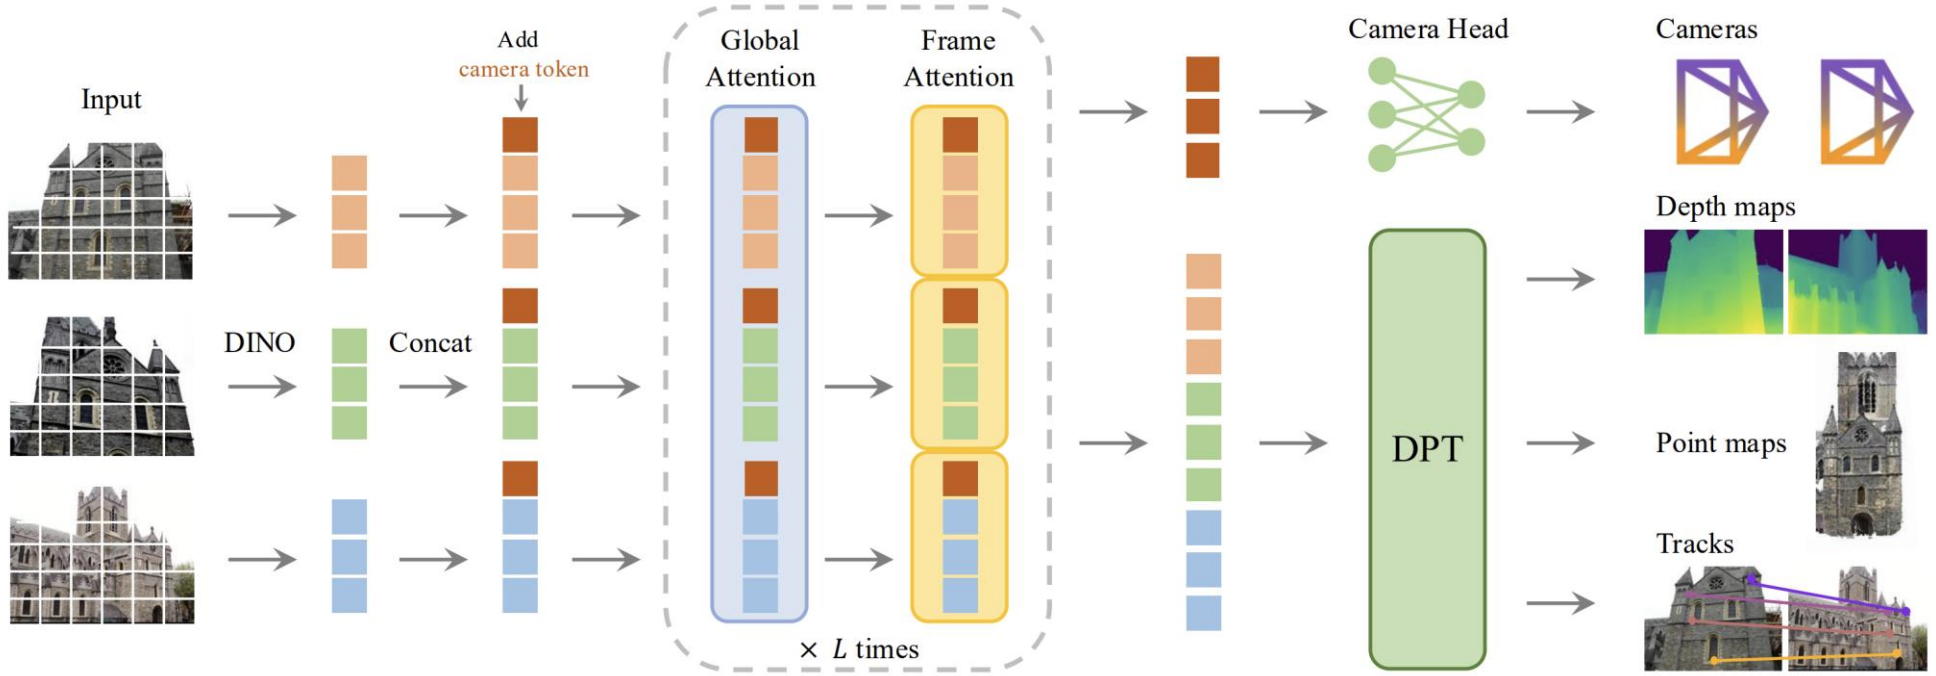
Global alignment는 pair 내부가 아닌 scene 전체의 consistency를 맞추는 단계

VGGT: 여러 view의 관계를 network 내부에서 함께 처리함

Pairwise reconstruction 이후의 사후 통합을 multi-view joint prediction으로 대체함

DUSt3R §3.4

Method: VGGT Architecture Overview



DINOv2 image tokens + Camera / Register tokens

Alternating-Attention으로 여러 view의 features를 공동 처리

Shared backbone에서 cameras, depth maps, point maps, tracking features를 예측

VGGT §3.1–3.3; Figure 2

Method: Alternating-Attention

Frame-wise self-attention

동일 image의 tokens끼리 attention 수행

Image 내부의 정보를 처리하고, camera token과 해당 image features를 연결함

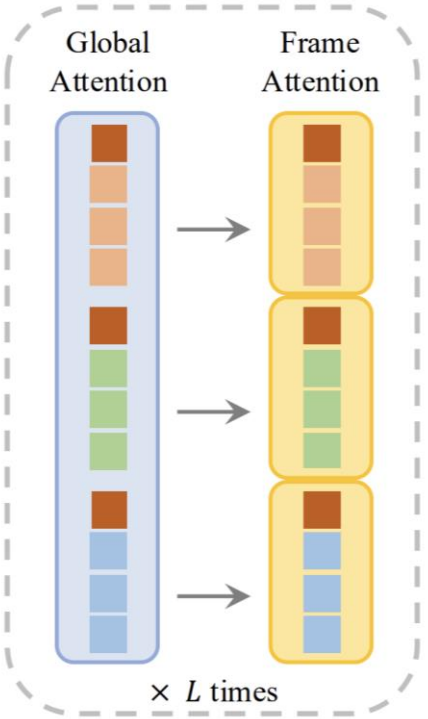
→ Eliminates frame index embedding

Global self-attention

모든 images의 tokens를 함께 처리함

View 사이의 정보를 교환하고 scene 전체의 일관된 geometry 추론을 지원함

→ Ensures scene-level coherence



DUSt3R의 two-branch cross-attention과 달리, self-attention을 번갈아 사용함

VGGT §3.2

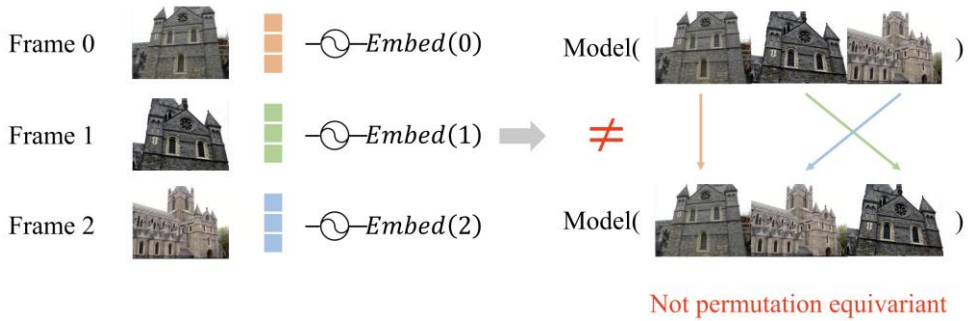
Method: Input Order and Reference Frame

Frame index embedding에 의존하지 않는 image collection 처리

Frame-wise attention으로 대체하여 각 token의 image 소속을 유지하면서도 입력 순서 의존성을 제거함

학습에서 사용한 frame 개수보다 긴 입력에도 적용 가능함

Frame index embedding을 추가하면 생기는 순서 의존성



Reference frame은 예외

첫 번째 image는 공통 좌표계를 지정하므로 특별한 tokens로 구분됨

나머지 images의 순서 변경에 대해서 permutation equivariance를 갖도록 설계함

VGGT §3.1–3.3; VGGT slides p.10–12

Method: Prediction Heads

Head / Branch	입력	출력
Camera head	Camera tokens	Rotation, translation, field of view
Depth branch	Image tokens	Per-view depth map
Point map branch	Image tokens	공통 reference의 3D coordinates
Tracking branch	Dense tracking features + query points	query point 대응하는 Per-view 2D locations

DUSt3R과의 차이

DUSt3R은 point maps로부터 cameras, depth, matches를 유도함

VGGT는 관련 geometry quantities를 명시적인 prediction targets로 함께 학습함

VGGT §3.3; DUSt3R §3.3

Method: Training and Over-complete Predictions

Multi-task objective

$$\mathcal{L} = \mathcal{L}_{\text{camera}} + \mathcal{L}_{\text{depth}} + \mathcal{L}_{\text{pmap}} + \lambda \mathcal{L}_{\text{track}}.$$

Camera Parameter error

Confidence-weighted depth/point map error

Correspondence와 visibility error

Over-complete predictions

Depth + Cameras로 point maps를 계산할 수 있어 출력 사이에 중복이 존재함

△ 관련 task를 공동 supervision하는 것이 geometry learning에 도움을 줌

Training에서는 함께 예측하고, inference에서는 필요한 branch 선택

Point map 직접 출력과 Depth + Cameras를 통한 unprojection을 실험에서 비교함

VGGT §3.1, §3.4; VGGT slides p.13

Experiments: Benchmarks and Baselines

Task	Benchmark	Metric / 평가 관점
Camera pose estimation	Re10K, CO3Dv2	AUC@30 ↑, runtime
Dense reconstruction	DTU	Accuracy / Completeness / Overall ↓
Point map estimation	ETH3D	Accuracy / Completeness / Overall ↓
Image matching	ScanNet-1500	Correspondence 기반 relative pose AUC ↑
Downstream transfer	GSO, TAP-Vid	NVS quality / dynamic point tracking

Baselines

Optimization-based: COLMAP, DUSt3R, MASt3R, VGGSfM

Feed-forward methods: Fast3R, CUT3R, FLARE, MV-DUSt3R

GT cameras의 사용 여부와 feed-forward / post-optimization 조건을 구분하여 비교함

VGGT §4, Tables 1–8

Discussions

Limitations: 입력 camera model과 scene 변화의 제약

- Fisheye, panoramic images를 지원하지 않음
- Extreme input rotations에서 성능이 저하됨
- 큰 non-rigid deformation에서는 실패함 (시점만 달라지는 게 아니라 geometry가 크게 달라지는 것)

△ flexibility와 쉬운 adaptation 덕분에, 약간의 architecture 변경과 fine-tuning으로 해결 가능함!

Runtime and Memory: 많은 view에 대한 계산 비용

View 수가 증가할수록 runtime과 GPU memory 요구량이 커짐

Differentiable BA: 가능성은 있지만 큰 학습 비용

Camera와 3D point를 반복적으로 수정하고, 그 오차를 BA 이전의 neural network까지 역전파하는 것

소규모 사전 실험에서는 좋은 성능을 냈으나, training 시 연산 비용이 매우 커서 대규모 학습에 부적합 → 최종 VGGT에 포함하지 않음

△ 3D annotation이 없는 시나리오에서 효과적인 supervision signal이 될 수 있어, 대규모 unsupervised 학습에 유망한 방향임!

VGGT §5

Summary: DUSt3R and VGGT

비교 축	DUSt3R	VGGT
Network 입력 단위	Image pair	여러 images
View 간 정보 교환	Two-branch cross-attention	Frame-wise / global self-attention
주요 직접 출력	Point maps + confidence	Cameras, depth, points, tracking features
Multi-view integration	Global alignment	Network 내부 공동 추론
Training objective	Point map regression 중심	여러 geometry task 공동 학습
사후 optimization	Multi-view 정합에 사용	기본 결과에 필수 아님, BA 추가 가능

DUSt3R의 pairwise geometry regression을 multi-view joint prediction으로 확장함

VGGT의 핵심: 공동 추론 구조, multi-task supervision, 빠르고 유용한 geometry outputs

Idea & Discussion

DUSt3R과 VGGT 둘 다 reference coordinate을 첫번째 이미지 카메라로 잡는데,

다른 이미지에서의 view를 reference coordinate으로 삼으면 성능이 더 높아지지 않을까?

→ 검증 연구

Thank You