NExT-GPT

: Any-to-Any Multimodal LLM

ICML 2024 (Oral)

2026.10.08.

Jungyeon Lee

Background and RQ

멀티모달 이해에서 멀티모달 생성까지

입력에서 이미지·오디오·비디오를 이해하는 모델이 늘었지만,
출력은 텍스트 또는 텍스트+이미지에 머무는 경우가 많다.

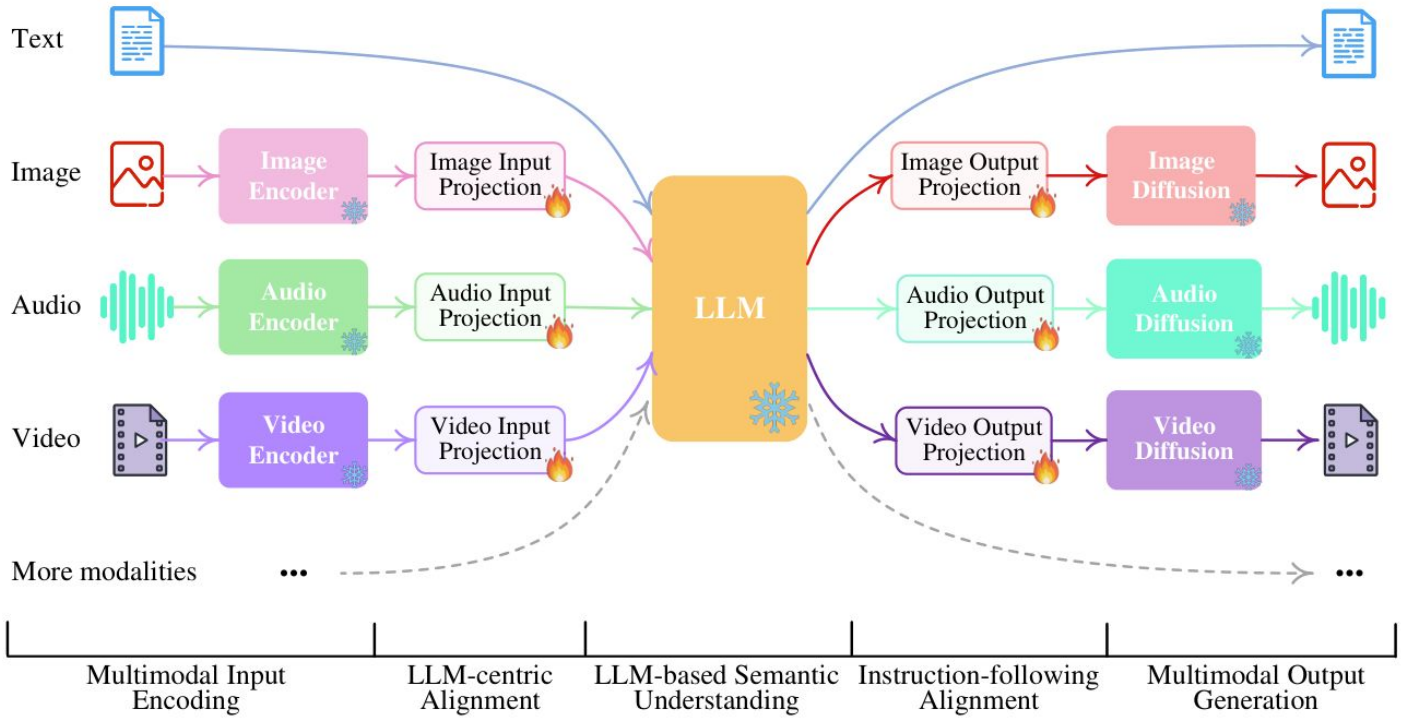
핵심 질문

LLM의 의미 이해·추론 능력을 유지하면서,
텍스트·이미지·오디오·비디오의 다양한 입출력 조합을 지원할 수 있는가?

NExT-GPT의 제안

pre-trained module을 LoRA로 연결하고,
입출력 alignment 학습과 Modality-switching Instruction Tuning (MosIT)을 결합한다.

Overall Architecture



Input Encoding

ImageBind +
Grouping projection

Understanding/Inference

Vicuna-7B
Text + X (modality)
signal token

Generation

Output projection +
Diffusion decoder

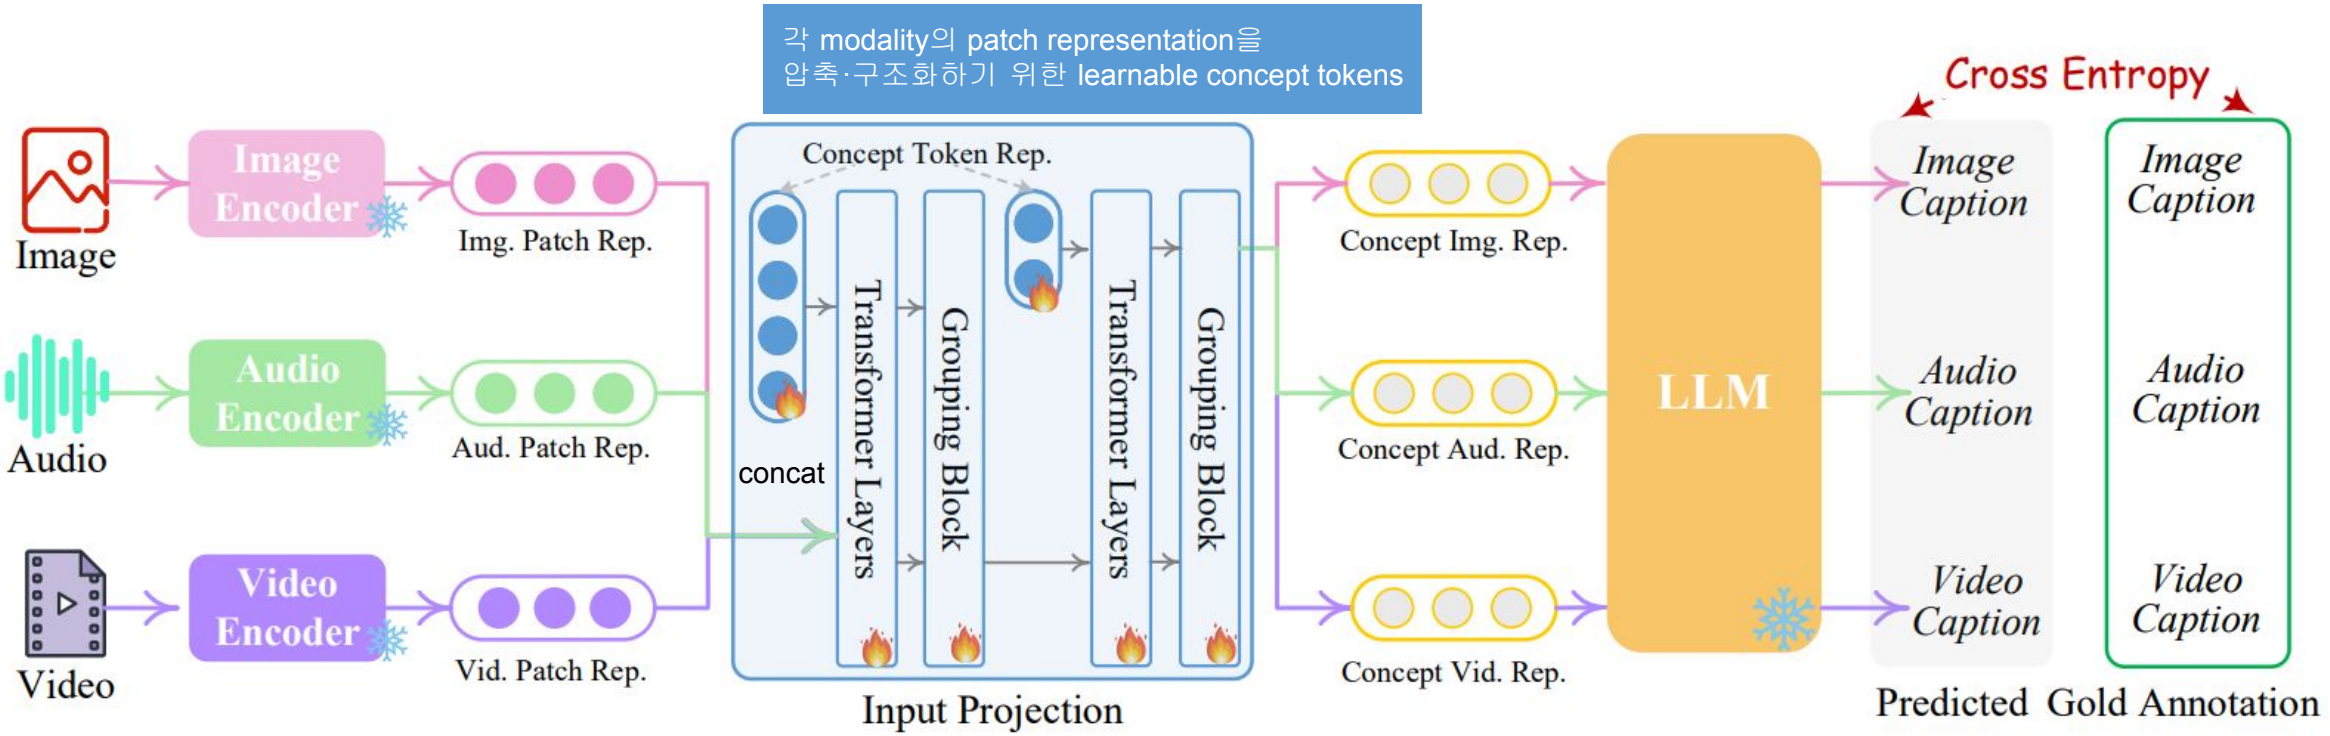
Overall Architecture (Cont'd)

	Encoder		Input Projection		LLM		Output Projection		Diffusion	
	Name	Param	Name	Param	Name	Param	Name	Param	Name	Param
Text	—	—	—	—			—	—	—	—
Image					Vicuna	7B❄	Transformer	31M🔥	SD	1.3B❄
Audio	ImageBind	1.2B❄	Grouping	28M🔥	(LoRA	33M🔥)	Transformer	31M🔥	AudioLDM	975M❄
Video							Transformer	32M🔥	Zeroscope	1.8B❄

학습 대상 155M / 전체 약 12.43B ≈ 1.25%

Efficiently requiring only minimal parameter adjustments

Encoding-side LLM-centric Multimodal Alignment



Why Grouping?

작은 patch의 특징과 text token의 의미 단위가 잘 맞지 않을 수 있음
Learnable concept token으로 관련 특징을 모아 LLM에 전달

Decoding-side Instruction-following Alignment

텍스트 응답과 modality signal token을 함께 생성

LLM은 일반 텍스트와 함께 [IMG], [AUD], [VID] signal token을 출력
→ signal token이 나타나면 해당 modality decoder를 활성화

Signal token의 hidden state가 생성 내용을 전달

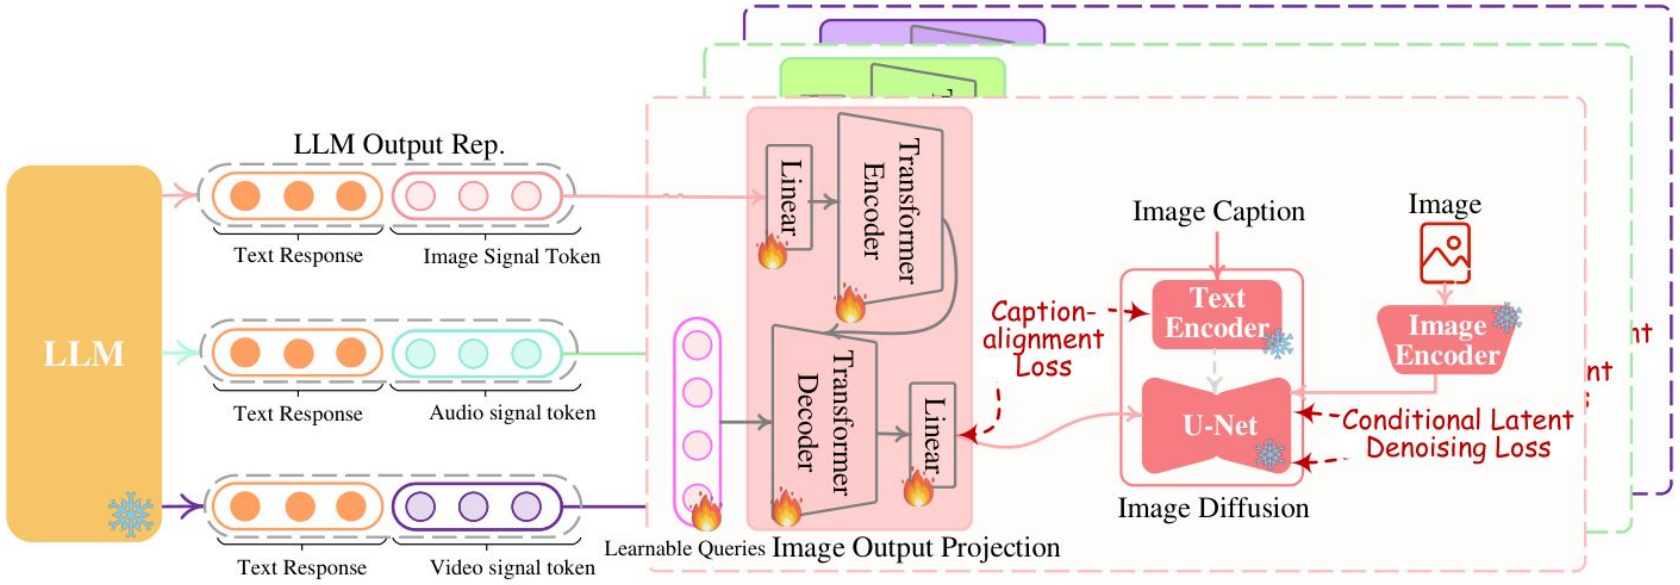
Signal token 위치의 hidden state는 **무엇을 생성할지에 대한 문맥 정보**를 담음
Output projection은 이를 **diffusion model의 conditioning space에 맞는 representation**으로 변환

e.g.

"비 오는 밤의 도시를 보여줘"
→ LLM이 텍스트 + [IMG] signal token 생성
→ projected hidden representation이 image diffusion model을 condition
→ 요청에 맞는 이미지 생성

Signal token = 어떤 modality를 생성할지
Hidden representation = 무엇을 생성할지

Decoding-side Instruction-following Alignment



The NLL of producing signal tokens

올바른 출력 모달리티의 신호 토큰을 생성하도록

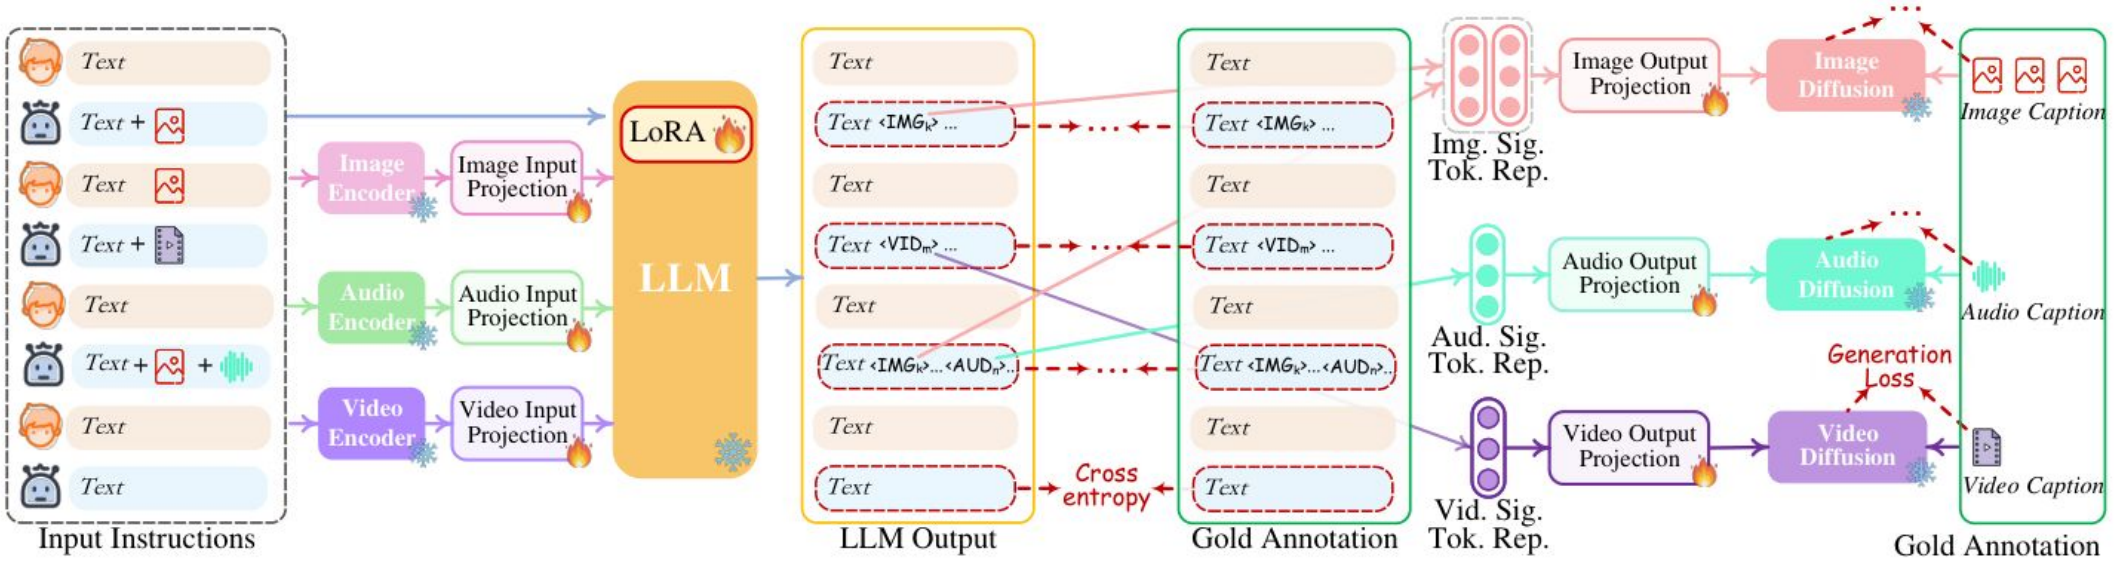
Caption-alignment Loss

신호 토큰의 hidden rep.을 diffusion text encoder의 caption rep.과 가깝게 정렬

Conditional Latent Denoising Loss

projected signal rep.을 조건으로 diffusion model이 올바른 latent를 복원하도록 학습

Instruction Tuning & LoRA



- 캡션 생성이나 생성 조건 정렬만으로는 암묵적인 의도나 대화의 맥락, 출력 모달리티 선택까지 충분히 학습하기 어렵기 때문에 decoding 단계에서의 alignment도 필요

- **LoRA**: LLM의 기본 가중치를 freeze하고 작은 low-rank 업데이트를 학습

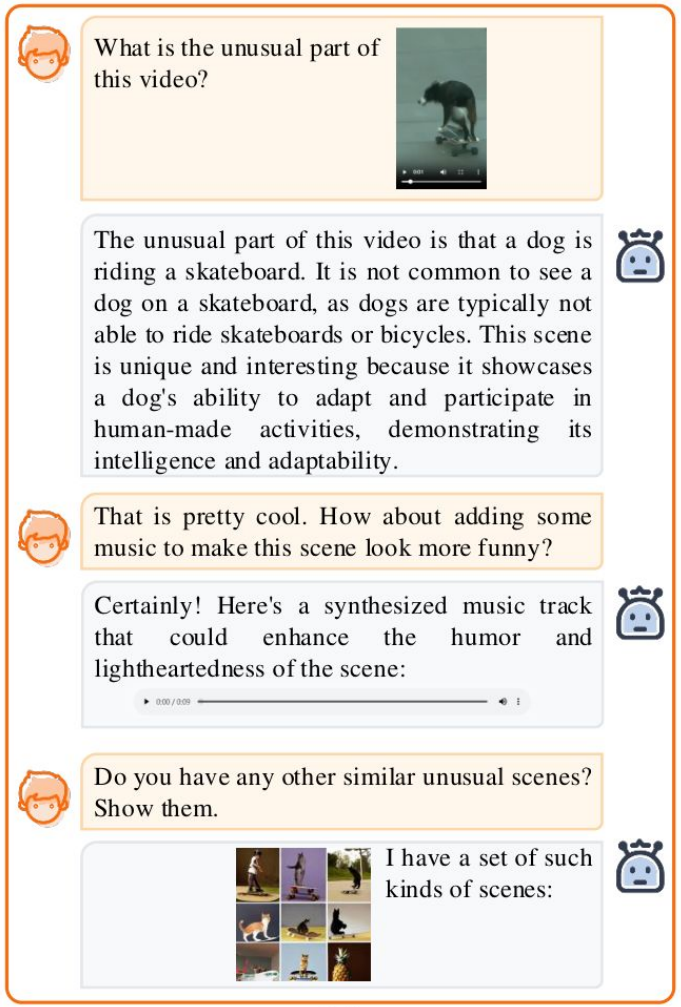
Instruction Dataset

데이터	규모·구성	학습하려는 행동
기존 데이터셋	Alpaca, LLaVA-150K, VideoChat	다양한 비텍스트 입력에 대해 텍스트 출력 생성
T2M	15K / 이미지·오디오·비디오 각 5K 주로 단일 턴	텍스트 요청에 비텍스트 콘텐츠 생성 (Text-to-Multimodal)
MosIT	5K 대화 / 3–7턴, 평균 4.8턴 100개 이상 주제·키워드	대화 맥락을 유지하며 입출력 모달리티 전환 (Any-to-any)

구축 과정

GPT-4 대화 초안 생성, 외부 검색·AIGC 콘텐츠 대응, 사람의 검수·필터링
명시적 요청뿐 아니라 추론·제안·계획과 암묵적 요청을 포함한다.

MosIT Data Example



(A)

1. 비디오 이해

“이 비디오에서 특이한 점은?”
→ 스케이트보드를 타는 개라는 장면에 대한 텍스트 응답 생성

2. 오디오 생성

“더 재미있게 느껴지도록 음악을 추가해줘”
→ 장면의 분위기에 맞는 오디오 생성

3. 이미지 생성

“비슷하게 특이한 장면을 보여줘”
→ 대화 맥락에 맞는 이미지 사례 생성

Exp Results: Image Understanding

모델	COCO CIDEr ↑	VQAv2 ↑	VizWiz ↑	OKVQA ↑	MMB ↑
InstructBLIP	102.2	—	33.4	33.9	36.0
DreamLLM	115.4	56.6	45.8	44.3	49.9
Video-LLaVA	—	**74.7**	48.1	—	**60.9**
NExT-GPT	**124.9**	66.7	**48.4**	**52.1**	58.0

Image captioning과 OKVQA에서 강점을 보인다.
VQAv2 · MMB에서는 Video-LLaVA가 더 높아, 과제별 성능 차이가 존재한다.

Exp Results: Video/Audio Understanding

모델	MSR-VTT 캡셔닝 ↑	MSVD-QA ↑	MSRVTT-QA ↑	NExTQA ↑	AudioCaps 캡셔닝 ↑
CoDi	74.4*	—	—	—	78.9*
UIO-2XXL	48.8*	41.5	52.1	—	48.9*
Video-LLaVA	—	**70.7**	59.2	—	—
NExT-GPT	**76.2***	64.5	**61.4**	**50.7**	**81.3***

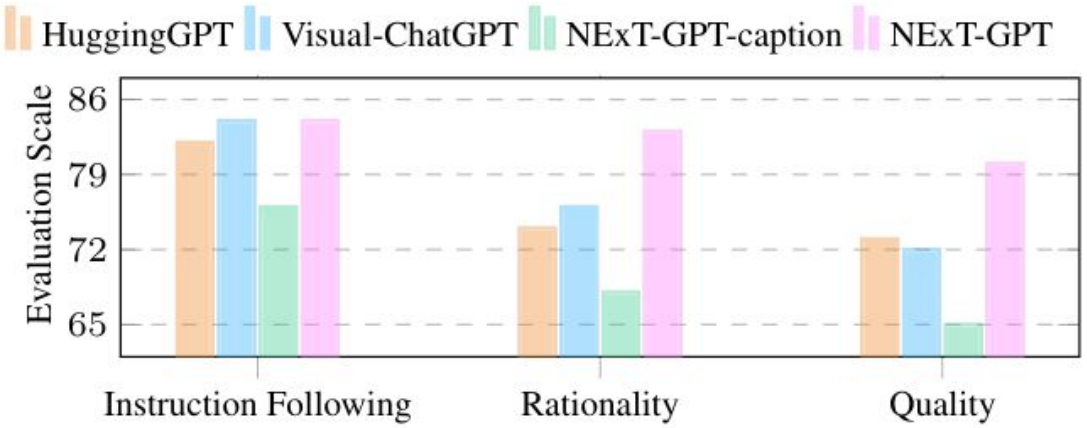
* 해당 태스크의 학습 데이터로 추가 학습한 결과

Exp Results: Text-to-X Generation

모델	이미지 FID ↓	오디오 FAD ↓	비디오 CLIPSIM ↑
Stable Diffusion 1.5	11.21	—	—
CoDi	11.26	1.80	28.90
AudioLDM-L	—	1.96	—
GILL-8B (zero-shot)	12.20	—	—
NExT-GPT (zero-shot)	**11.18**	**1.74**	**30.96**
NExT-GPT	**10.07**	**1.68**	**31.97**

FID · FAD는 생성 분포의 품질, CLIPSIM은 텍스트–비디오 의미 유사성을 평가

Human Evaluation



텍스트+이미지 평가이며, 모든 모달리티 전환을 평가한 결과는 아니다.

평가 설계

GPT-4가 만든 복잡한 지시 100개
텍스트+이미지 응답을 5명이 평가
지시 이행·합리성·품질의 평균 점수

기존 방식:
LLM이 텍스트 instruction/caption을 만들고 외부 generation tool에 넘기는 pipeline

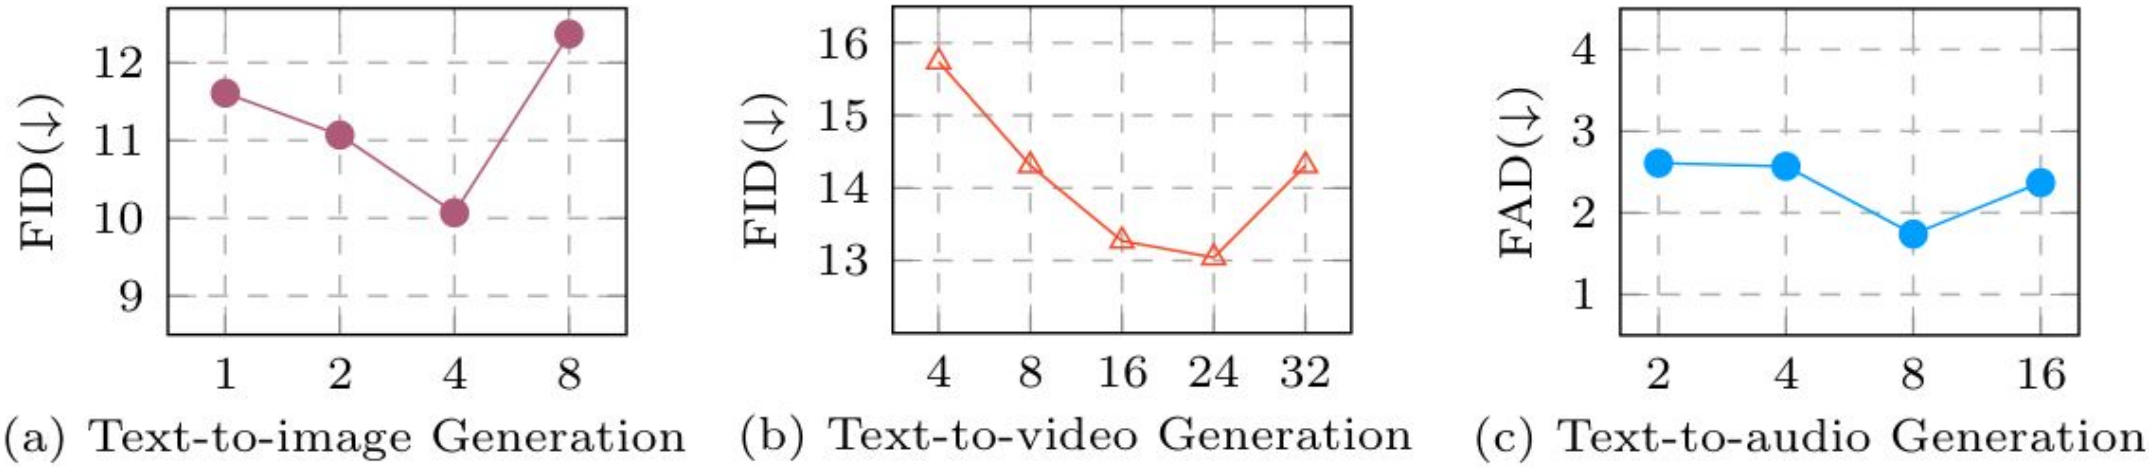
vs.

NExT-GPT: LLM과 multimodal decoder 사이를 soft representation으로 연결하고 alignment training

Exp: The Impact of Grouping Mechanism

Input Projection	VQAv2 ↑	VizWiz ↑	MSVD-QA ↑	MSRVTT-QA ↑	AudioCaps ↑
Linear Layer	63.8	45.4	60.8	57.1	77.4
Q-former + Linear Layer	65.1	46.9	63.4	58.1	79.7
Grouping (NExT-GPT)	**66.7**	**48.4**	**64.5**	**61.4**	**81.3**

Exp: # of modality signal tokens



이미지

약 4개에서 좋은 FID
8개에서는 다시 악화

비디오

약 24개에서 좋은 FID
더 복잡한 정보를 전달

오디오

약 8개에서 좋은 FAD
16개에서는 다시 악화

적절한 토큰 수는 모달리티 · 학습 데이터 · 디코더 구성에 따라 달라진다.

Contributions

LLM 중심의 이해와 생성 연결

LLM이 출력 종류와 내용을 결정하고, 학습 가능한 연결부가 생성 조건을 전달
Human Evaluation에서 캡션 전달 변형보다 좋은 결과를 보임

사전학습 모듈을 재사용하는 경량 학습

약 155M의 연결부·LoRA만 학습 (약 1%의 파라미터만 훈련)
Grouping projection은 단순 linear layer보다 높은 이해 성능을 보임

모달리티 전환을 데이터로 학습

T2M과 MosIT로 비텍스트 출력 및 multi-turn 전환을 지도
새 모달리티를 연결하는 설계 기반 제시

Limitations and Future Work

Limitations

1. 현재 지원 범위는 네 모달리티
   (Text, Image, Video, Audio)
2. 기반 LLM은 Vicuna-7B
3. 생성 품질은 diffusion decoder의 능력에 의존
4. MosIT의 규모·다양성 확장이 필요

Future Work

1. 모달리티·태스크 확장
   : 웹페이지, 3D, 히트맵, 표·그림 등
2. 다양한 LLM 종류·크기 도입
3. 검색 기반 방법으로 생성 보완
4. 규모·다양성 확대

Paper Critique

Limitations

1. 모든 입출력 조합의 정량 평가 부족
2. 출력 간 일관성과 장기 대화 오류 측정 부족
3. 합성 지시의 편향·일반화 검토 필요
4. 전체 지연 시간·메모리·연산량 비교 필요

Future Work

1. 새 모달리티의 디코더마다 얼마나 재정렬해야 하는가?
2. LLM 규모(성능)와 데이터 규모의 효과는 다른가?
3. 검색(retrieval)이 사실성·일관성을 개선하는가?
4. 스위칭 데이터(MosIT)가 익숙하지 않은 조합에도 일반화하는가?

Discussion

- 생성 결과가 instruction과 다른 경우, 어디를 어떻게 개선할 것인가?
  - LLM reasoning / modality signal generation, output projection alignment, or diffusion decoder?
- MosIT의 modality-switching 효과를 base LLM 성능이나 단순한 데이터 규모 증가 효과와 어떻게 분리해 검증할 수 있는가?

Q&A

Thank you