AnyGPT

: Unified Multimodal LLM with Discrete Sequence Modeling

ACL 2024

2026.10.27.

Jungyeon Lee

Related Work & Key Idea

기존 방식의 한계

- **CoDi (2023) :** Robust core LM 부족 → 시스템의 추론, 의사결정 능력 저해
- **NExTGPT (2023), CoDi-2 (2023), Unified-IO2 (2023) :**
  별도로 사전학습된 인코더, 디코더 사용 → LLM의 입출력 표현 불일치가 학습, 추론을 복잡하게 만듦
- **NExTGPT (2023) :**
  - LLM 학습 X → suboptimal performance일 수 있음
  - 입출력이 통합된 형태를 갖추지 않음 → 통합 학습 및 추론에 어려움이 있음

LoRA 학습 단계 有.
다소 과장된 서술…

핵심 내용

“Multimodal Learning as Next-Token Prediction”

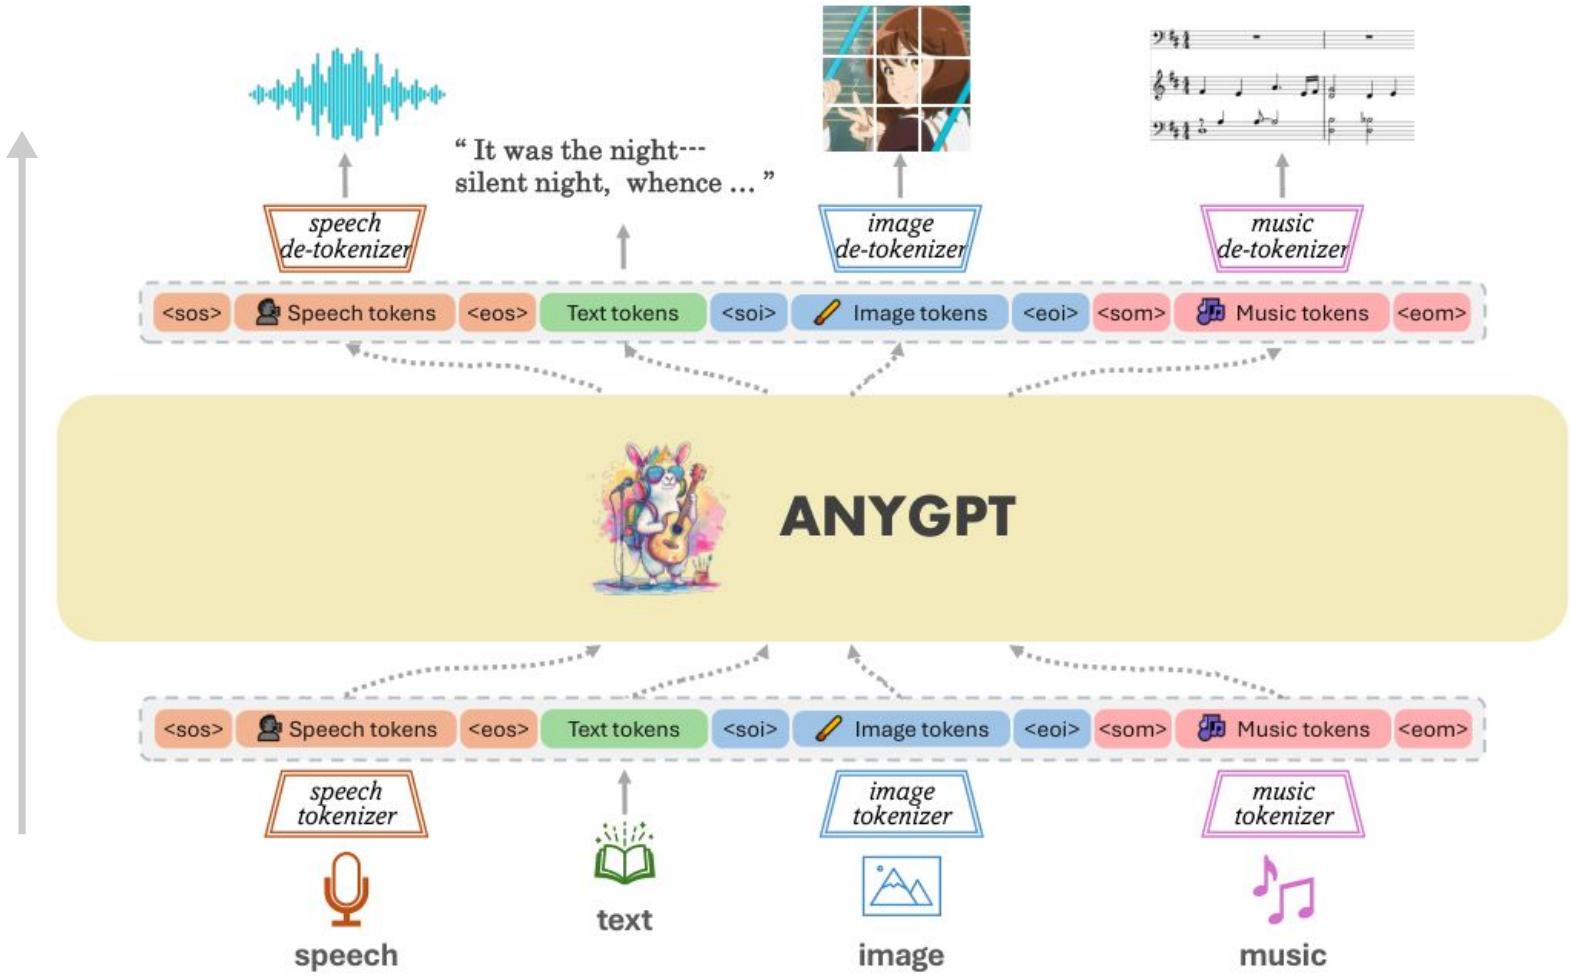
모달리티마다 별도의 표현 정렬 및 생성 방식을 설계하는 대신, 모든 모달리티를 이산 토큰으로 변환하여 기존 LLM의 Autoregressive Modeling Framework 안에서 통합적으로 이해하고 생성한다.

Comparison with NExT-GPT

비교	NExT-GPT	AnyGPT
Input rep.	continuous embedding	**discrete token**
Output rep.	LLM signal → diffusion condition	**discrete token**
I/O interface	비대칭	통일된 token sequence
Alignment	모달리티별 projection으로 표현 공간 정렬	확장 어휘와 next-token prediction으로 통합
강점	적은 학습 파라미터, 기존 생성 모델 활용	통일된 모델링 및 학습 방식
지원 범위	**텍스트·이미지·오디오·비디오**	**텍스트·이미지·음성·음악**

- **NExT-GPT**: 서로 다른 모달리티의 사전학습 모델들을 연결하는 modular integration approach
- **AnyGPT**: 모든 모달리티를 discrete token으로 표현하여 하나의 autoregressive modeling framework로 통합하려는 unified sequence modeling approach
  ~ 기존 LLM 아키텍처나 학습 패러다임을 전혀 변경하지 않고 모델 안정적 학습 가능!

AnyGPT



Tokenizer로 이산 토큰화
LLM이 다음 토큰을 직접 예측
De-tokenizer로 콘텐츠 복원

Preliminary: VQ-VAE

Continuous 데이터를 discrete 코드로 압축하는 AutoEncoder

Encoder의 연속 벡터를 학습 가능한 codebook의 최근접 벡터로 치환하고, Decoder가 데이터를 복원한다.
강력한 Decoder가 잠재 표현을 무시하는 posterior collapse 문제를 다루기 위해 제안되었다.

$$k = \text{argmin}_{□} \| z_e(x) - e_{□} \|^2 \quad zq(x) = e_{□}$$

LLM에 전달할 토큰은 정수 인덱스 k이며, Decoder는 이에 대응하는 벡터 $e_{□}$를 입력받는다.

세 가지 Training Loss

Loss	Role
Reconstruction Loss	원본과 복원 결과의 차이를 줄인다.
Codebook Loss	선택한 codebook vector를 Encoder 출력에 가깝게 이동한다.
Commitment loss	Encoder 출력이 선택한 codebook vector에 머물도록 한다.

AnyGPT에서:

모달리티별 코드 인덱스를 토큰 시퀀스로 표현하여 LLM의 next-token prediction에 사용한다.

Preliminary: **RVQ**

잔차(residual)를 여러 코드북으로 반복 보정하는 quantization

Encoder의 연속 표현 x에서 코드북 벡터를 선택하고, 남은 잔차를 다음 단계에서 다시 양자화한다.
각 단계는 자신의 코드북에서 **현재 잔차와 가장 가까운 벡터를 선택**한다.

단계	선택한 코드북 벡터	남은 잔차
1단계	$v_1 = Q_1(x)$	$r_1 = x - v_1$
2단계	$v_2 = Q_2(r_1)$	$r_2 = r_1 - v_2$
n단계	$v_n = Q_n(r_{n-1})$	$r_n = r_{n-1} - v_n$

복원: 각 인덱스의 벡터를 조회해 합산한다. $\hat{x} = v_1 + v_2 + \ldots + v_n$
이 근사 잠재 벡터를 Decoder에 입력하여 원본 데이터를 복원한다.

장점과 AnyGPT에서의 활용

작은 코드북을 조합해 표현 정밀도를 높이고, 단계 수로 토큰 수와 비트레이트를 조절할 수 있다.
각 단계의 인덱스만 저장하며, 뒤 단계는 앞 단계에서 남은 세부 오차를 보완한다.

AnyGPT: 음성은 8계층 중 첫 계층을 LLM이 모델링하고, 음악은 4계층을 모두 사용한다.

Tokenization by Modality

원본 데이터를 LLM이 예측할 수 있는 정수 코드로 변환

	SEED	SpeechTokenizer	Encodec
Modality	Image	Speech	Music
Vocab Size	8192	1024	4096
Tokens per Sample	32 / per image	50 / s	200 / s
RVQ	✘	✔	✔
Input Size	224*224	variable duration	5s

음성: 의미 정보와 음향 정보를 분리

SpeechTokenizer는 8개 RVQ 계층을 사용한다. LLM은 첫 계층만 모델링하고,
나머지 7개 계층의 화자·음색 등 세부 정보는 생성 단계에서 보완한다.

음악은 5초를 250 frames × 4 codes = 1,000 tokens로 표현한다.

Language Model Backbone

Expanding vocabulary

하나의 확장된 vocab: 텍스트 vocab에 이미지, 음성, 음악의 전용 토큰을 가지고 만든 새 어휘를 추가
Embedding과 output prediction layer를 확장하고, 새 파라미터는 무작위로 초기화

Unified Multimodal Language Model / LLaMA-2 7B

Next token prediction loss으로 학습 가능
텍스트와 비텍스트 토큰을 한 시퀀스에 배치하고, 앞 문맥으로 다음 토큰을 예측한다.
$L = -\Sigma\square \log p_\theta(z\square \mid z_1, \ldots, z\square_{-1})$

경계 토큰으로 모달리티를 구분

이미지 <soi> … <eoi> 음성 <sos> … <eos> 음악 <som> … <eom>
모달리티마다 서로 다른 어휘를 쓰되, 동일한 Transformer 안에서 문맥을 함께 모델링한다.

Transformer 구조와 학습 목표를 유지하며, 모달리티별 별도 regression loss를 추가하지 않는다.

Multimodal Generation

LLM의 토큰 예측 / 모달리티별 복원 분담

LLM은 discrete sequence의 의미, 문맥을 모델링한다.
이미지와 음성의 세부적인 지각 정보는 non-autoregressive 생성 모듈이 보완한다.

Output	LLM이 생성하는 내용	최종 콘텐츠 복원
Image	32개 SEED 이미지 토큰	생성 embedding으로 변환 후 diffusion 복원
Speech	SpeechTokenizer 의미 토큰	SoundStorm이 음향 토큰을 보완한 뒤 decoding
Music	4개 RVQ 계층의 EnCodec 토큰	EnCodec decoder로 파형 복원

3초 음성 프롬프트를 이용한 음색 조건부 생성

음성 생성 시 짧은 참조 음성으로 화자 특성을 조건화한다.
LLM이 모든 음향 계층을 직접 예측하는 부담을 줄인다.

Pre-training Data

텍스트를 공통 연결점으로 모달리티 정렬

모든 모달리티가 함께 관측되는 데이터는 부족하다.
텍스트–X 쌍을 양방향으로 학습해 여러 모달리티가 같은 LLM 안에서 의미를 공유하도록 한다.

데이터	구성·규모	학습 내용
이미지–텍스트	필터링한 약 300M pairs LAION 계열·JourneyDB	이미지 이해와 이미지 생성
이미지·텍스트 혼합	MMC4-core 7.3M documents	문서 속 교차 모달리티 문맥
음성–텍스트	57,000시간의 영어 음성 GigaSpeech·Common Voice·MLS	음성 인식과 음성 합성
음악–텍스트	100만 개 이상 영상에서 수집 메타데이터를 GPT-4로 캡셔닝	음악 이해와 음악 생성

학습 시 데이터 혼합·oversampling을 적용하며, 최대 시퀀스 길이는 4,500 tokens이다.

AnyInstruct-108k

다양한 모달리티가 섞인 multi-turn instruction synthetic data

텍스트 중심 정렬에 더해, **대화 맥락에 맞는 모달리티 선택과 응답 형식을 지도**한다.

1. 주제와 대화 상황 생성

GPT-4로 100개 상위 주제를 확장해
20,000개 세부 주제와 대화 상황을 만든다.

2. 텍스트 형태의 대화 작성

이미지, 음악을 [설명문]으로 표시하고,
여러 모달리티를 섞은 multi-turn 대화를 만든다.

3. 설명문을 실제 콘텐츠로 변환

이미지: DALL-E 3
음악: MusicGen
음성: Microsoft Azure TTS

4. 필터링 후 108k 대화 확보

이미지 약 205k개, 음성 약 503k개,
음악 약 113k개를 포함한다.
별도로 음성 대화 100k개도 추가한다.

Fine-tuning용 dataset

Exp Results: Image

Pre-trained base AnyGPT의 zero-shot 평가로 이미지 이해와 생성의 alignment 성능을 측정

Image captioning

모델	CIDEr ↑
Flamingo (9B)	79.4
Flamingo (80B)	84.3
Emu (14B)	112.4
DreamLLM (8B)	115.4
InstructBLIP (14B)*	102.2
SEED-LLaMA (8B)*	**123.6**
AnyGPT (8B)	107.5

MS-COCO 2014 Karpathy test split
* Training samples로 학습한 baselines

Text-to-image generation

모델	CLIPscore ↑
GILL	0.67
Emu	0.66
SEED-LLaMA	**0.69**
AnyGPT	0.65

MS-COCO validation의 30k captions
CLIP-ViT-L로 이미지–설명 유사도 측정

Exp Results: Speech

ASR: 음성을 텍스트로 전사

LibriSpeech test-clean
WER: 단어 오류율, 낮을수록 좋음

모델	WER ↓
Wav2vec 2.0	**2.7**
Whisper Large V2	**2.7**
AnyGPT	8.5

AnyGPT는 음성 인식/생성을 모두 수행하지만,
ASR 오류율은 표의 전문 모델보다 높다.

TTS: 텍스트로 음성 생성

VCTK의 미학습 화자와 3초 참조 음성
WER 및 화자 유사도(SIM) 평가

모델	WER ↓	SIM ↑
Ground Truth	*1.9*	*0.93*
VALL-E	7.9	0.75
USLM	**6.5**	**0.84**
AnyGPT	8.5	0.77

WER는 두 비교 모델보다 높다.
SIM은 VALL-E보다 높고 USLM보다 낮다.

Exp Results: Music

MusicCaps에서 이해와 생성 평가

CLAPscore는 음악과 텍스트 설명 간 의미 유사도를 측정

Music understanding

평가 쌍	CLAPscore ↑
음악 + 실제 캡션	0.16
음악 + AnyGPT 생성 캡션	0.11

캡셔닝은 같은 음악에 대해 실제 캡션과
생성 캡션의 의미 정렬 정도를 비교한다.

Music generation

모델	CLAPscore ↑
Riffusion	0.19
Mousai	**0.23**
AnyGPT	0.14

음악 생성은 두 비교 모델보다 낮은 점수다.
본 설정의 음악 길이는 5초로 제한한다.

Contributions

다중 모달리티를 하나의 시퀀스 모델링 문제로 통합

텍스트, 이미지, 음성, 음악의 discrete token을 한 LLM에서 이해하고 생성한다.
기존 Transformer와 next-token prediction 학습 방식을 유지한다.

AnyInstruct-108k: 다양한 입출력 조합을 위한 instruction 데이터 구축

AnyInstruct-108k로 모달리티가 교차하는 multi-turn 대화를 supervise한다.
사전학습은 텍스트를 매개로 정렬하고, instruction tuning은 대화 형식과 모달리티 선택을 학습한다.

범용 모델에서 여러 모달리티의 기본 능력을 확인

이미지, 음성, 음악의 양방향 태스크를 zero-shot으로 평가하고,
튜닝 후 모델의 any-to-any 대화를 사례로 제시한다.

Limitations and Future Work

Limitations

전용 any-to-any 벤치마크 부족

단일 모달리티 학습보다 높은 loss

Tokenizer 품질이 성능 상한을 제한

긴 시퀀스와 5초 음악 길이 제한

Future Work

여러 입출력 조합과 대화 능력을
함께 평가할 종합 벤치마크 구축

LLM · tokenizer 규모 확장 및
Mixture-of-Experts 구조 탐색

Codebook 학습과 통합 표현 개선,
모달리티 정보 분리 연구

더 긴 context로 콘텐츠 길이와
대화 턴 수 확장

Limitations and Future Work

Limitations

전용 any-to-any 벤치마크 부족

단일 모달리티 학습보다 높은 loss

Tokenizer 품질이 성능 상한을 제한

긴 시퀀스와 5초 음악 길이 제한

Future Work

여러 입출력 조합과 대화 능력을 함께 평가할 종합 벤치마크 구축

UniM (2026), MME-Unify (2026), IMUG-Bench (2026). Modality Maturity Index (2026) 등 존재

LLM·tokenizer 규모 확장 및 Mixture-of-Experts 구조 탐색

Codebook 학습과 통합 표현 개선, 모달리티 정보 분리 연구

더 긴 context로 콘텐츠 길이와 대화 턴 수 확장

Research Idea

- **UniM (2026)**: Text, Image, Audio, Video, Document, Code, 3D 7개 모달리티, 30개 도메인에 대해 any-to-any interleaved multimodal benchmark 제안 but multi-turn 대화 X
- **MME-Unify (2026)**: Multimodal understanding과 generation을 통합해 평가할 수 있는 벤치마크 제안
- **IMUG-Bench (2026)**: 대화가 여러 턴에 걸쳐 진행될 때 모델의 understanding/generation 능력이 일관되게 유지되는지 평가할 수 있는 벤치마크 제안
- **OmniDialog (2024)**: 다양한 '입력' 모달리티 활용하는 multi-turn 대화 이해 및 일반화 능력에 초점을 맞춘 벤치마크
- **Modality Maturity Index (2026)**: Text, Image, Audio, Video, Document 5개 모달리티. 최대 3개의 입/출력 모달리티 조합 평가. 서로 다른 모달리티 조합을 얼마나 정확하게 처리하는가 평가할 수 있는 벤치마크

⇒ **여러 모달리티를 이해하고 생성하는 능력 + 여러 턴에 걸쳐 맥락을 유지하면서 적절한 모달리티로 응답하는 능력**을 하나의 벤치마크에서 종합적으로 평가하기는 어렵다.

Q&A



Thank you